

중고차 데이터 분석 및 가격 예측 서비스 보고서

1. 문제정의

이번 프로젝트는 중고차 매물 데이터를 이용해 차량 조건에 따라 가격이 어떻게 달라지는지 확인하고, 사용자가 입력한 조건으로 예상 가격을 볼 수 있는 Streamlit 웹 서비스를 만드는 것을 목표로 했다.

- 사용 데이터: `data/used_cars.csv` , `data/enriched_used_cars.csv`
- 데이터 형식: CSV
- 데이터 규모: 원본 4,009행, 보강 데이터 기준 9,273행
- 데이터 출처: Kaggle - Used Car Price Prediction Dataset by Taeef Najib, reBrowser CARFAX sample dataset, EPA vehicle data, NHTSA recall data
- 라이선스: 기본 매물 데이터는 Kaggle 데이터셋 기준을 따르고, CARFAX/EPA/NHTSA 데이터는 보조 데이터로 사용
- 예측 대상: `price`
- 서비스 형태: Streamlit 기반 EDA, 시각화, 가격 예측 웹 앱
- 추가 기능: 업/다운 가격 예측 게임, 가성비 차량 추천, 외부 데이터 기반 구입 판독, 한국 기준 시세 보정

2. 데이터 전처리

원본 데이터에서는 가격과 주행거리가 문자열로 들어와 있어서, 분석과 모델 학습 전에 숫자로 바꾸는 작업이 필요했다.

- `price` : `$10,300` 형식에서 `$` , `,` 제거 후 숫자형 변환
- `price_usd` : 원본 달러 가격 보존
- `price` : 앱 표시와 예측 기준을 맞추기 위해 원화로 변환
- `milage` : `51,000 mi.` 형식에서 `,` , `mi.` 제거 후 숫자형 변환
- `model_year` : 정수형 변환
- 결측값: `fuel_type` , `accident` , `clean_title` , `transmission` 등은 `Unknown` 으로 대체
- 파생 변수: `car_age` , `price_per_mile` , `accident_flag` , `brand_model`
- 외부 데이터: EPA 연비, NHTSA 리콜 수, CARFAX 최신 샘플 매물 정보를 매칭해 추천과 판독 기능에 사용

3. EDA 발견

- 가격은 대부분 일반적인 가격대에 몰려 있었지만, 일부 초고가 차량이 평균을 크게 흔들 수 있었다.

- 브랜드별 평균 가격과 매물 수에는 차이가 있었다.
- 연식이 최신일수록 평균 가격이 높아지는 경향이 보였다.
- 주행거리가 늘어날수록 가격은 낮아지는 흐름을 확인했다.
- 사고 또는 손상 이력 여부도 가격 비교에서 중요한 변수로 볼 수 있었다.

4. 시각화 구성

Streamlit 앱의 시각화 페이지에서는 다음 그래프를 제공한다.

- 전체 가격 분포 히스토그램
- 일반 가격대 세부 분포 히스토그램
- 가격 구간별 매물 수 막대그래프
- 가격 상위 1% 초고가 매물을 따로 보여주는 비싼차 모음집
- 브랜드별 평균 가격 막대그래프
- 연식별 평균 가격 선 그래프
- 주행거리와 가격의 산점도
- 사고 이력 여부별 가격 박스플롯

5. 모델 및 서비스

가격 예측 서비스는 `RandomForestRegressor` 를 사용해 구현했다.

- 입력 변수: 브랜드, 모델, 연식, 주행거리, 연료 유형, 변속기, 사고 이력, 클린 타이틀 여부
- 예측값: 예상 중고차 가격
- 전처리: 수치형 변수 표준화, 범주형 변수 원-핫 인코딩
- 이상치 처리: 가격 상위 1% 초고가 매물은 모델 학습에서 제외
- 제외된 초고가 매물 93건은 비싼차 모음집으로 별도 표시

모델 성능은 다음과 같다.

- 평균 절대 오차: 약 14,982,985원 (약 \$9,777)
- R^2 : 약 0.677

성능 지표는 현재 앱에서 사용하는 보강 데이터(`data/enriched_used_cars.csv`)와 원화 변환 가격 기준으로 다시 계산했다.

6. 결론

이번 프로젝트에서는 EDA, 시각화, 머신러닝 예측 기능을 하나의 Streamlit 앱으로 묶었다. 사용자는 필터로 중고차 데이터를 살펴보고, 차량 조건을 입력해 예상 가격을 확인할 수 있다. 단순히 그래프를 보여주는 데서 끝내지 않고, 사용

자가 직접 눌러보면서 판단할 수 있는 서비스 형태로 만든 점이 의미 있었다.

가격 예측 게임도 추가해서 사용자가 실제 차량 정보를 보고 가격을 추측해볼 수 있게 했다. 또 가성비 차량 추천, 외부 데이터 기반 구입 판독, 한국 기준 시세 보정 기능을 붙여서 분석 결과가 실제 의사결정에 조금 더 가깝게 이어지도록 했다.

7. 한계 및 개선 방향

- 트림, 옵션, 사고 수리 범위 정보가 부족해 실제 가격을 완전히 설명하기는 어렵다.
- 판매 지역, 판매 시점, 개인/딜러 여부, 인증중고차 여부를 반영하지 못했다.
- Kaggle 기반 샘플 데이터라 현재 실시간 시세와 차이가 있을 수 있다.
- 해외 데이터 기반이라 한국 원화 가격으로 해석할 때 환율과 시장 차이가 있다.
- 기본 매물 데이터와 보조 데이터의 성격이 다르므로 출처를 구분해서 설명해야 한다.
- 희소 모델이나 초고가 차량은 예측 오차가 커질 수 있다.
- 향후 Linear Regression, XGBoost 등과 비교해 모델 선택 근거를 강화할 필요가 있다.
- 더 많은 실제 매물 데이터와 옵션 정보를 확보하면 예측 신뢰도를 개선할 수 있다.