

중고차 데이터 분석 및 가격 예측 서비스 보고서

중고차 데이터 분석 및 가격 예측 서비스 보고서

1. 문제정의

본 프로젝트는 중고차 매물 데이터를 활용하여 차량의 브랜드, 모델, 연식, 주행거리, 연료 유형, 사고 이력 등에 따른 가격 차이를 분석하고, 사용자가 입력한 차량 조건을 바탕으로 예상 가격을 제공하는 Streamlit 웹 서비스를 제작하는 것을 목표로 한다.

- 사용 데이터: `data/used_cars.csv`
- 데이터 형식: CSV
- 예측 대상: `price`
- 서비스 형태: Streamlit 기반 EDA, 시각화, 가격 예측 웹 앱
- 추가 기능: 실제 매물 데이터를 활용한 업/다운 가격 예측 게임

2. 데이터 전처리

원본 데이터에는 가격과 주행거리가 문자열 형태로 저장되어 있어 분석과 모델 학습 전에 숫자형으로 변환했다.

- `price`: `$10,300` 형식에서 `$`, `,` 제거 후 숫자형 변환
- `milage`: `51,000 mi.` 형식에서 `,`, `mi.` 제거 후 숫자형 변환
- `model_year`: 정수형 변환
- 결측값: `fuel_type`, `accident`, `clean_title`, `transmission` 등은 `Unknown` 으로 대체
- 파생 변수: `car_age`, `price_per_mile`, `accident_flag`, `brand_model`

3. EDA 발견

- 중고차 가격은 대부분 일반 가격대에 분포하지만 일부 초고가 차량이 존재한다.
- 브랜드별로 평균 가격과 매물 수에 차이가 있다.
- 최신 연식 차량일수록 평균 가격이 높아지는 경향이 있다.
- 주행거리가 증가할수록 가격이 낮아지는 경향을 확인할 수 있다.
- 사고 또는 손상 이력 여부는 가격 비교에 중요한 변수로 활용될 수 있다.

4. 시각화 구성

Streamlit 앱의 시각화 페이지에서는 다음 그래프를 제공한다.

- 전체 가격 분포 히스토그램
- 일반 가격대 세부 분포 히스토그램
- 가격 구간별 매물 수 막대그래프
- 가격 상위 1% 초고가 매물을 따로 보여주는 비싼차 모음집
- 브랜드별 평균 가격 막대그래프
- 연식별 평균 가격 선 그래프
- 주행거리와 가격의 산점도
- 사고 이력 여부별 가격 박스플롯

5. 모델 및 서비스

가격 예측 서비스는 `RandomForestRegressor` 를 사용하여 구현했다.

- 입력 변수: 브랜드, 모델, 연식, 주행거리, 연료 유형, 변속기, 사고 이력, 클린 타이틀 여부
- 예측값: 예상 중고차 가격
- 전처리: 수치형 변수 표준화, 범주형 변수 원-핫 인코딩
- 이상치 처리: 가격 상위 1% 초고가 매물은 모델 학습에서 제외
- 제외된 초고가 매물 41건은 비싼차 모음집으로 별도 표시

모델 성능은 다음과 같다.

- 평균 절대 오차: 약 `$12,141`
- R^2 : 약 `0.609`

6. 결론

본 프로젝트는 EDA, 시각화, 머신러닝 예측 기능을 하나의 Streamlit 앱으로 통합했다. 사용자는 필터를 통해 중고차 데이터를 탐색하고, 차량 조건을 입력하여 예상 가격을 확인할 수 있다. 단순 분석 결과를 보여주는 데서 끝나지 않고 실제 사용자가 활용할 수 있는 예측 서비스 형태로 확장했다는 점에서 의미가 있다.

추가로 가격 예측 게임을 구현하여 사용자가 실제 차량 정보를 보고 가격을 추측하고, UP/DOWN 피드백을 받으며 데이터의 가격 패턴을 체험할 수 있도록 했다.

7. 한계 및 개선 방향

- 차량 옵션, 판매 지역, 판매 시점, 판매자 유형 등의 정보가 없어 실제 가격을 완전히 설명하기 어렵다.

- 회소 모델 또는 초고가 차량의 경우 예측 오차가 커질 수 있다.
- 향후 더 많은 데이터를 확보하고 추가 변수를 반영하면 예측 정확도를 개선할 수 있다.
- 모델별 세부 옵션과 사고 정도를 반영하면 더 현실적인 가격 예측 서비스로 발전시킬 수 있다.