

기말 프로젝트 안내 (남은 4주: 3작업 + 1발표)

한 줄 목표: 내가 고른 데이터를 EDA→시각화→예측/서비스까지 묶어 혼자서 실행되는 **Streamlit 웹 앱 1개**를 만들고 발표한다.

지금까지 배운 걸 "가이드 따라" 한 번씩 해봤습니다(7·10주 웹공격 분류, 11·12주 이미지 분류). 이번엔 **같은 파이프라인을, 내가 고른 데이터로, 혼자** 하는 것뿐입니다. 새로운 기술은 없습니다.

1. 전체 일정 한눈에 보기 (남은 4번의 수업)

시점	무엇을	끝나면 손에 남는 것 (제출/체크)
1차 작업 전 (준비)	(지난 과제) 후보 3개 검토 + 각 후보로 뭘 하고 싶은지 한 줄씩 생각해 오기	후보 3개 + 아이디어 메모
① 1차 작업 (3h)	기획(데이터 1개 확정·문제정의·서비스 설계) + 데이터 적재 + EDA 착수	문제정의.md 완성 + EDA 페이지 시작
② 2차 작업 (3h)	EDA 마무리 + 시각화 페이지 + 전처리·특성 엔지니어링	시각화 페이지 + src/features.py
③ 3차 작업 (3h)	모델/서비스 페이지 (입력→예측→결과)	서비스 페이지 동작 (MVP)
3차→발표 사이 (과제)	앱 마무리 + 보고서 작성	보고서.md (또는 PDF) 완성
④ 발표 (기말)	발표 + 제출	발표자료 + 코드 + 보고서 제출 → 기말 30%

핵심: 작업 수업은 **3회(9시간)**, 마지막은 발표입니다. **기획(데이터 확정·문제정의·서비스 설계)**은 **1차 수업에서 교수님과 함께** 합니다 — 데이터 선택이 프로젝트 성패를 가르므로 혼자 정하지 말고 점검받으세요. 보고서·마무리는 과제로. 세션 사이 과제: ①→② EDA 마무리·발견 정리 / ②→③ 특성 다듬기 / ③→④ 보고서·앱 마무리.

2. 기획 — 1차 작업에서 교수님과 함께 (미리 준비물 포함)

지난 시간에 **후보 3개**를 골랐습니다. 1차 작업 첫 시간에 그중 **1개**를 **확정**하고, 아래 **문제정의.md**를 수업에서 **함께** 작성합니다(교수님 점검).

미리 준비물: 후보 3개를 다시 열어보고, **각 후보로 무엇을 하고 싶은지 한 줄씩** 적어 오세요.

프로젝트 문제정의

1. 선택한 데이터

- 이름 / 출처(URL) / 라이선스:
- 크기(행, 열) / 형식(csv, 이미지, 텍스트...):
- 어떻게 받았나(다운로드 / Open API / 크롤링):

2. 풀고 싶은 문제

- 한 문장으로: "____ 데이터로 ____ 를 ____ 하고 싶다"
- 예측/분류 대상(target)이 있나? 있으면 무엇:

3. 만들 서비스(완성 모습)

- 사용자가 무엇을 입력하면 → 무엇을 보여주는 앱인가:
- 사용할 기술(아래 중 택1 이상): ML / 딥러닝(사전학습) / LLM(HuggingFace·Ollama)

4. 예상 난관 1가지

데이터 고르는 기준 (이걸로 거르세요)

- ☒ **target(예측할 컬럼)이 명확하거나, 텍스트/이미지처럼 사전학습 모델에 바로 넣을 수 있는 데이터**
- ☒ **행 수백~수만 정도. 너무 크면(수백만 행, 수십 GB) 수업 시간에 못 끝냅니다**
- ☒ **결측치·인코딩이 지옥이 아닌 것 (한 번 열어보고 판단)**
- ☒ **비밀번호·로그인 뒤에 있어 못 받는 데이터, 라이선스 불명 데이터**

못 고르겠으면 안전한 출처: 공공데이터포털, 캐글(Kaggle), HuggingFace Datasets, 서울열린데이터광장

3. "서비스/모델" 어디까지 하면 합격인가 (MVP 기준)

처음부터 모델을 학습시키지 않아도 됩니다. 강의실 GPU는 8GB라 무거운 학습은 못 끝냅니다. 아래 중 **하나만 동작해도 통과**입니다. 욕심내지 말고 먼저 동작부터 시키세요.

데이터 종류	가장 쉬운 합격 경로	배운 곳
표(숫자/범주)	scikit-learn RandomForest/LogisticRegression 분류·회귀	10주
표 + 설명이 필요	위 + Ollama/LLM로 결과 해설 붙이기	6·10주
텍스트	HuggingFace pipeline (감성·요약·분류) 또는 Ollama	5·6주
이미지	사전학습 ViT pipeline (파인튜닝 안 해도 됨)	11·12주

최소 동작(MVP) = 사용자가 값/파일을 입력 → 모델·LLM이 결과 반환 → Streamlit 화면에 표시. 여기까지 되면 그 다음에 정확도 올리기·시각화 꾸미기를 합니다. **순서를 지키세요.**

4. 권장 앱 구조 (템플릿 제공)

`project_template/` 폴더를 복사해서 시작하세요. 5주차 영화 대시보드와 **똑같은 멀티페이지 구조**입니다.

```
my_project/
├── app.py           # 진입점 (st.navigation) – 건드릴 일 거의 없음
├── pages/
│   ├── 1_EDA.py    # 1차 작업: 데이터 요약·결측·분포
│   ├── 2_시각화.py  # 2차 작업: plotly/altair 그래프
│   └── 3_모델_서비스.py # 3차 작업: 입력→예측→결과
├── src/
│   └── data_loader.py # 데이터 읽기 (@st.cache_data)
```

```

├── features.py      # 정제·특성 만들기
├── data/           # 데이터 파일 (용량 크면 .gitignore)
├── 이미지_데이터_쓸_때/ # 이미지 프로젝트면 이 안내대로 2파일 교체
├── requirements.txt
└── 보고서.md       # 템플릿의 보고서_템플릿.md 를 복사해 작성

```

실행:

```

cd my_project
pip install -r requirements.txt
streamlit run app.py

```

이미지 데이터를 고른 경우: 표(CSV)와 적재·EDA 방식이 다릅니다. 템플릿의 **이미지_데이터_쓸_때/** 폴더 안내대로 **2개 파일(data_loader.py, 1_EDA.py)**만 교체하면 됩니다(샘플 이미지 포함, 바로 실행). 모델은 §3의 이미지 경로(ViT pipeline)를 그대로 사용.

5. 자주 막히는 곳 (FAQ)

Q. 데이터가 너무 커서 안 열려요. → `pd.read_csv(..., nrows=50000)`로 일부만 불러 개발하고, 마지막에 전체로 바꾸세요.

Q. 모델 학습이 강의실 PC에서 안 돌아가요(메모리 부족). → 학습하지 말고 **사전학습 모델/pipeline/Ollama**를 쓰세요(3번 표). `device = 0 if torch.cuda.is_available() else -1`.

Q. 앱을 새로고침할 때마다 모델이 다시 로드돼 느려요. → 모델 로드 함수에 `@st.cache_resource`, 데이터 로드 함수에 `@st.cache_data`를 붙이세요(12주 app.py 참고).

Q. 팀으로 해도 되나요? → 이번 기말 프로젝트는 **개인 프로젝트**입니다. 각자 본인이 고른 데이터로 진행하세요.

Q. 시간이 부족할 것 같아요. → 3번 MVP만 먼저 완성하세요. "동작하는 단순한 앱" > "안 돌아가는 화려한 앱". 채점도 그렇게 합니다(루브릭 참고).

6. 발표 주 제출물 체크리스트

제출 방법: 아래를 모두 담아 ① **GitHub 저장소 링크**(1주차에 배운 Git 사용) 또는 ② **zip 파일 업로드** 중 편한 방식으로 제출하세요. (데이터가 크면 데이터는 빼고 출처 URL을 보고서에 적기)

- ☐ `streamlit run app.py`로 **에러 없이** 뜨는 앱
- ☐ EDA 페이지 (요약/결측/분포 그래프)
- ☐ 시각화 페이지 (인사이트가 보이는 그래프 ≥ 2개)
- ☐ 모델/서비스 페이지 (입력→예측→결과)
- ☐ **보고서.md** (또는 PDF) — 문제정의·EDA발견·모델·결론·한계
- ☐ 발표자료 (5분 발표 기준)
- ☐ `requirements.txt` (다른 PC에서도 설치되도록)

평가 세부 배점은 **평가_루브릭.md** 를 꼭 읽어보세요.