

10,000건 데이터 분석과 60,000건 데이터 분석의 차이점 보고서

CSIC 2010 HTTP 요청 데이터셋 EDA 결과 비교

보고서의 핵심 질문

동일한 분석 코드를 사용했을 때, 10,000건의 샘플 데이터를 분석한 결과와 61,065건의 확장 데이터를 분석한 결과는 어떤 차이를 보이는가?

비교 대상 파일

- eda_visualization (1).ipynb: 10,000건 데이터 분석
- eda_visualization-all.ipynb: 61,065건 데이터 분석

1. 분석 목적

본 보고서는 두 노트북 파일 자체의 코드 차이를 비교하는 것이 아니라, **분석 데이터의 규모가 달라졌을 때 EDA 결과가 어떻게 달라지는지**를 중심으로 정리한다. 두 파일은 분석 흐름과 시각화 코드가 거의 동일하므로, 결과 차이의 원인은 주로 데이터 개수의 차이에서 발생한다.

핵심 결론

10,000건 분석과 61,065건 분석은 전체적인 패턴은 거의 동일하다. 그러나 61,065건 분석에서는 더 많은 공격 키워드와 예외 사례가 발견되어, **결과의 신뢰도와 일반화 가능성**이 더 높다. 반대로 10,000건 분석은 빠른 실습과 경향 파악에는 적합하지만, 일부 정상 데이터의 오탐 가능성이나 드문 공격 패턴을 충분히 보여 주기에는 한계가 있다.

2. 데이터 규모 및 구성 차이

구분	10,000건 분석	61,065건 분석	차이 해석
전체 데이터 수	10,000건	61,065건	약 6.1배 증가
정상 요청	5,895건	36,000건	정상 데이터도 약 6.1배 증가
공격 요청	4,105건	25,065건	공격 데이터도 약 6.1배 증가
정상 비율	약 59.0%	약 58.9%	비율은 거의 동일
공격 비율	약 41.1%	약 41.1%	공격 비율 유지

두 데이터셋은 크기는 크게 다르지만 정상과 공격의 비율은 거의 동일하다. 따라서 10,000건 데이터는 전체 데이터의 축소 샘플처럼 볼 수 있다. 다만 표본 수가 작기 때문에 드문 패턴이나 정상 데이터에 섞인 공격 유사 문자열은 충분히 드러나지 않을 수 있다.

3. HTTP 메서드별 분석 결과 차이

메서드	10,000건 전체	10,000건 공격	10,000건 공격 비율	61,065건 전체	61,065건 공격	61,065건 공격 비율
GET	6,984	2,434	34.9%	43,088	15,088	35.0%
POST	2,945	1,600	54.3%	17,580	9,580	54.5%
PUT	71	71	100.0%	397	397	100.0%

HTTP 메서드별 결과는 두 분석에서 거의 같은 패턴을 보인다. GET은 전체 요청 중 가장 많지만 공격 비율은 약 35%이고, POST는 공격 비율이 약 54%로 더 높다. PUT은 두 분석 모두에서 전부 공격 요청으로 나타난다.

이 결과는 데이터가 10,000건에서 61,065건으로 늘어나도 **메서드별 공격 경향이 유지된다**는 점을 보여준다. 즉, 10,000건 분석만으로도 큰 방향성은 파악할 수 있지만, 61,065건 분석은 이 경향이 우연이 아니라는 점을 더 강하게 뒷받침한다.

4. URL 길이와 Body 길이 차이

구분	10,000건 URL 평균	61,065건 URL 평균	10,000건 Body 평균	61,065건 Body 평균	해석
공격 요청	73.0	73.0	47.0	45.0	공격 요청은 긴 URL/Body 경향 유지
정상 요청	50.0	48.0	20.0	20.0	정상 요청은 상대적으로 짧 음

구분	10,000건 URL 최대	61,065건 URL 최대	10,000건 Body 최대	61,065건 Body 최대
공격 요청	637	641	604	611
정상 요청	328	328	287	299

길이 통계는 두 분석에서 매우 유사하다. 공격 요청의 URL 평균 길이는 두 분석 모두 73.0으로 동일하고, 정상 요청보다 길다. Body 길이도 공격 요청이 정상 요청보다 길게 나타난다.

따라서 데이터가 6배 이상 늘어나도 **공격 요청은 정상 요청보다 길이가 길다**는 특징은 유지된다. 이는 URL 길이와 Body 길이가 공격 탐지 모델에서 유용한 특징으로 활용될 수 있음을 의미한다.

5. 공격 키워드 분석 차이

5-1. 공격 유형별 키워드 발견 수

공격 유형	10,000건 공격 내 발견	61,065건 공격 내 발견	증가 배율	해석
SQL Injection	1,391	8,163	약 5.9배	가장 많이 발견되는 공격 유형
CRLF Injection	249	1,480	약 5.9배	전체 데이터에서 더 안정적으로 확인
XSS	232	1,286	약 5.5배	대표 키워드 패턴 유지
Command Injection	34	216	약 6.4배	소규모 데이터에서는 드물게 보임
Path Traversal	33	194	약 5.9배	전체 데이터에서 더 명확히 확인

공격 유형별 순위는 두 분석에서 거의 동일하다. SQL Injection이 가장 많이 나타나고, CRLF Injection과 XSS가 뒤를 따른다. 그러나 61,065건 분석에서는 각 공격 유형의 출현 수가 많아져 결과 해석이 더 안정적이다.

특히 Command Injection, Path Traversal처럼 상대적으로 빈도가 낮은 공격은 10,000건 분석에서는 발견 수가 30건대에 불과하다. 이런 경우 작은 데이터만 보고 일반화하면 위험하다. 전체 데이터 분석에서는 해당 공격들이 약 200건 전후로 확인되어 패턴을 더 신뢰할 수 있다.

5-2. 주요 키워드별 발견 수

키워드	10,000건 공격 발견	61,065건 공격 발견	차이 해석
'	518	2,994	SQL Injection 계열 핵심 특수문자
insert	437	2,588	정상/공격 양쪽에서 모두 발견되어 주의 필요
--	309	1,828	공격 집중도가 매우 높음
%0a	156	932	CRLF Injection 관련 키워드
<script	106	572	XSS 공격 패턴
alert(	100	550	XSS 공격 패턴
select	37	212	전체 데이터에서 정상 사례도 일부 발견
/etc/passwd	33	194	Path Traversal 공격 패턴

10,000건 분석에서도 주요 공격 키워드의 순위는 어느 정도 드러난다. 하지만 61,065건 분석에서는 키워드별 발견 수가 크게 늘어나며, 공격 패턴의 반복성이 더 명확하게 확인된다.

6. 10,000건 분석에서 놓칠 수 있는 부분

가장 중요한 차이: 오탐 가능성 확인 여부

10,000건 분석에서는 `select` 키워드가 정상 요청에서 발견되지 않았다. 그러나 61,065건 분석에서는 정상 요청에서도 `select`가 2건 발견되었다. 이는 데이터가 커질수록 단순 키워드 기반 탐지의 한계가 더 잘 드러난다는 의미이다.

키워드	10,000건 정상 발견	61,065건 정상 발견	의미
<code>select</code>	0	2	작은 데이터에서는 오탐 가능성이 보이지 않음
<code>union</code>	0	2	전체 데이터에서 정상 문자열로도 등장
<code>insert</code>	327	2,000	정상 요청에서도 자주 등장
<code>'</code>	19	94	특수문자가 항상 공격을 의미하지는 않음

이 차이는 보고서에서 가장 중요하게 다뤄야 한다. 10,000건 데이터만 보면 특정 키워드가 공격 요청에만 존재하는 것처럼 보일 수 있다. 하지만 61,065건 데이터에서는 일부 공격 키워드가 정상 요청에서도 발견된다.

따라서 **키워드 하나만으로 공격 여부를 판단하는 방식은 위험**하다. 실제 분석에서는 키워드 존재 여부뿐 아니라 URL 길이, Body 길이, HTTP 메서드, 특수문자 조합, 키워드 위치, 요청 구조 등을 함께 고려해야 한다.

7. 분석 규모에 따른 장단점 비교

구분	10,000건 데이터 분석	61,065건 데이터 분석
장점	실행이 빠르고 실습용으로 적합하다. 전체적인 공격/정상 경향을 빠르게 확인할 수 있다.	분석 결과의 신뢰도가 높고, 드문 패턴과 오탐 가능성까지 확인할 수 있다.
단점	데이터가 적어 일부 예외 사례를 놓칠 수 있다. 드문 공격 유형의 발견 수가 적어 일반화에 한계가 있다.	실행 시간이 더 길고 출력 파일 크기가 커진다. 시각화 결과 저장 용량도 증가한다.
적합한 용도	수업 실습, 빠른 EDA 확인, 코드 검증	최종 보고서, 모델 학습 전 분석, 탐지 기준 도출
신뢰도	기본 경향 확인 수준	일반화 가능한 분석 근거 확보 가능

8. 최종 결론

10,000건 데이터 분석과 61,065건 데이터 분석은 큰 방향에서는 동일한 결론을 보인다. 공격 요청은 정상 요청보다 URL과 Body 길이가 길고, SQL Injection 관련 키워드가 가장 많이 나타나며, POST와 PUT 요청에서 공격 비율이 높다.

하지만 데이터 수가 61,065건으로 늘어나면서 분석의 깊이가 달라진다. 전체 데이터에서는 공격 키워드의 반복성이 더 뚜렷해지고, 상대적으로 드문 공격 유형도 충분히 관찰되며, 정상 요청 안에서도 공격 키워드와 유사한 문자열이 발견된다. 이 때문에 전체 데이터 분석은 단순한 경향 파악을 넘어 실제 탐지 기준의 한계와 오탐 가능성을 확인하는 데 더 적합하다.

따라서 10,000건 분석은 실습과 빠른 확인용으로 적절하고, 61,065건 분석은 최종 보고서 작성이나 머신러닝 모델 학습 전 탐색 분석에 더 적합하다. 특히 웹 공격 탐지에서는 단순 키워드 여부만이 아니라 여러 특징을 함께 조합하여 판단해야 한다.

9. 발표 또는 보고서용 요약문

본 분석에서는 동일한 EDA 코드를 사용하여 10,000건 데이터와 61,065건 데이터를 각각 분석하였다. 두 분석 모두 정상 요청과 공격 요청의 비율, HTTP 메서드별 공격 경향, URL 및 Body 길이 차이에서 유사한 결과를 보였다. 공격 요청은 정상 요청보다 URL과 Body 길이가 길었고, SQL Injection 관련 키워드가 가장 많이 발견되었다. 그러나 61,065건 전체 데이터를 분석했을 때는 더 많은 공격 키워드와 예외 사례가 확인되었다. 특히 10,000건 분석에서는 보이지 않았던 정상 요청 내 `select`, `union` 등의 키워드가 전체 데이터에서는 일부 발견되어, 단순 키워드 기반 탐지에는 오탐 가능성이 있다는 점을 확인할 수 있었다. 따라서 10,000건 데이터는 실습과 빠른 경향 파악에는 적합하지만, 최종 분석과 탐지 기준 도출에는 61,065건 데이터를 활용하는 것이 더 타당하다.